

Math Basis of Support Vector Machine

周陆延

1. 给出支持向量机最大间隔准则原问题的推导，解释分类超平面和支持超平面的含义

分类超平面为任意将样本划分为两个部分的超平面

支持超平面则是距离两侧支持向量距离之和最大的分类超平面

记样本点 x 到超平面 (ω, b) 的距离为

$$r = \frac{|\omega^\top x + b|}{\|\omega\|} \quad (1)$$

假设超平面能将样本分类则 $\exists (\omega, b)$ s.t. $\forall i$

$$\begin{cases} \omega^\top x_i + b \geq +1 & \text{if } y_i = +1 \\ \omega^\top x_i + b \leq -1 & \text{if } y_i = -1 \end{cases} \quad (2)$$

则称刚好使等号成立的样本点为支持向量，两个异类支持向量到超平面的距离和 $\gamma = \frac{2}{\|\omega\|_2^2}$ 为间隔，要使 γ 最大，即

$$\begin{aligned} \max \frac{2}{\|\omega\|_2^2} &= \min \frac{1}{2} \|\omega\|_2^2 \\ \text{s.t. } y_i(\omega^\top x_i + b) &\geq 1 \end{aligned} \quad (3)$$

2. 给出对偶问题的推导，并回答问题：强对偶性在支持向量机中始终成立吗？

对原问题应用拉格朗日乘数法

$$\begin{aligned} L(\omega, b, \alpha) &= \frac{1}{2} \|\omega\|_2^2 + \sum_{i=1}^m \alpha_i [1 - y_i(\omega^\top x_i + b)] \\ \text{s.t. } \alpha &\geq 0 \end{aligned} \quad (4)$$

首先证明原问题 \Leftrightarrow

$$\begin{aligned} \min_{\omega, b} \max_{\alpha} L(\omega, b, \alpha) \\ \text{s.t. } \alpha &\geq 0 \end{aligned} \quad (5)$$

证：

$$\begin{cases} \text{if } (\omega, b) \text{ 在可行域内} & \max_{\alpha} L(\omega, b, \alpha) = \frac{1}{2} \|\omega\|_2^2 + 0 + 0 \\ \text{if } (\omega, b) \text{ 不在可行域内} & \max_{\alpha} L(\omega, b, \alpha) = \frac{1}{2} \|\omega\|_2^2 + \infty + \infty \end{cases} \quad (6)$$

然后记对偶函数

$$g(\alpha) = \min_{\omega, b} L(\omega, b, \alpha) \quad (7)$$

对偶问题即为

$$\begin{aligned} \max_{\alpha} \min_{\omega, b} L(\omega, b, \alpha) \\ \text{s.t. } \alpha \geq 0 \end{aligned} \quad (8)$$

求偏导得

$$\begin{aligned} \frac{\delta L}{\delta \omega} = 0 \Rightarrow \omega = \sum_{i=1}^m \alpha_i y_i \mathbf{x}_i \\ \frac{\delta L}{\delta b} = 0 \Rightarrow \sum_{i=1}^m \alpha_i y_i = 0 \end{aligned} \quad (9)$$

带回原式即为

$$\begin{aligned} \max g(\alpha) &= \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \alpha_i y_i \alpha_j y_j \mathbf{x}_i^\top \mathbf{x}_j + \sum_{i=1}^m \alpha_i \left[1 - y_i \left(\left(\sum_{i=1}^m \alpha_i y_i \mathbf{x}_i^\top \right) \mathbf{x}_i + b \right) \right] \\ &= \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \alpha_i y_i \alpha_j y_j \mathbf{x}_i^\top \mathbf{x}_j + \sum_{i=1}^m \left(\alpha_i - \sum_{i=1}^m \alpha_i \alpha_j y_i y_j \mathbf{x}_j^\top \mathbf{x}_i - \alpha_i y_i b \right) \\ &= -\frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j y_i y_j \mathbf{x}_i^\top \mathbf{x}_j + \sum_{i=1}^m \alpha_i \\ \text{s.t. } \sum_{i=1}^m \alpha_i y_i &= 0 \end{aligned} \quad (10)$$

由支持向量机本身为凸优化问题且满足 Slater 条件（一定 $\exists(\omega, b)$ s.t. 某些点在 margin 内部），得强对偶性在支持向量机中始终成立

3. 根据前面的结果推导SVM的KKT条件

$$\begin{cases} \alpha_i \geq 0 \\ y_i(\omega^\top \mathbf{x}_i + b) \geq 1 \\ \alpha_i(y_i(\omega^\top \mathbf{x}_i + b) - 1) = 0 \end{cases} \quad (11)$$

4. 如果数据非线性可分怎么办？给出修改后的原问题和对偶问题

使用核技巧将数据映射到高维空间再进行划分

修改后的原问题：

$$\begin{aligned} \min_{\omega, b} \frac{1}{2} \|\omega\|_2^2 \\ \text{s.t. } y_i(\omega^\top \phi(\mathbf{x}_i) + b) \geq 1 \end{aligned} \quad (12)$$

修改后的对偶问题：

$$\begin{aligned} \max_{\alpha} \sum_{i=1}^m \alpha_i - \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j y_i y_j \kappa(\mathbf{x}_i, \mathbf{x}_j) \\ \text{s.t. } \sum_{i=1}^m \alpha_i y_i = 0 \end{aligned} \quad (13)$$

其中 $\phi(\mathbf{x})$ 是映射后的特征向量， $\kappa(\mathbf{x}_i, \mathbf{x}_j)$ 是两个向量在高维空间里的内积

5. 在问题3.4的基础上，若允许少量样本破坏约束，应增加怎样的损失函数，请给出修改后的原问题和对偶问题

应增加形如

$$C \sum_i^m \ell_{0/1}(y_i(\omega^\top x_i + b)) \quad (14)$$

的项，其中 $\ell_{0/1}$ 是 0/1 损失函数

$$\ell_{0/1}(z) = \begin{cases} 1 & \text{if } z < 1 \\ 0 & \text{otherwise} \end{cases} \quad (15)$$

但考虑到 $\ell_{0/1}(z)$ 较劣的数学性质，实际应用中通常寻找一些代替函数，如：

$$\begin{aligned} \ell_{\text{hinge}}(z) &= \max(0, 1 - z) \\ \ell_{\text{exp}}(z) &= \exp(-z) \\ \ell_{\log}(z) &= \log(1 + \exp(-z)) \end{aligned} \quad (16)$$

下面对选用 $\ell_{\text{hinge}}(z)$ 的原问题与对偶问题进行推导

原问题

$$\begin{aligned} \min \quad & \frac{1}{2} \|\omega\|_2^2 + C \sum_i^m \max(0, 1 - y_i(\omega^\top x_i + b)) \\ \text{s.t.} \quad & y_i(\omega^\top x_i + b) \geq 1 \end{aligned} \quad (17)$$

引入松弛变量 $\xi_i \geq 0$ 重写 式 17 得到修改后的原问题

$$\begin{aligned} \min \quad & \frac{1}{2} \|\omega\|_2^2 + C \sum_i^m \xi_i \\ \text{s.t.} \quad & \begin{cases} y_i(\omega^\top x_i + b) \geq 1 - \xi_i \\ \xi_i \geq 0 \end{cases} \end{aligned} \quad (18)$$

对偶问题为

$$\begin{aligned} \max_{\alpha} \quad & \sum_i^m \alpha_i - \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m \alpha_i \alpha_j y_i y_j x_i^\top x_j \\ \text{s.t.} \quad & \begin{cases} \sum_{i=1}^m \alpha_i y_i = 0 \\ 0 \leq \alpha_i \leq C \end{cases} \end{aligned} \quad (19)$$

其中和 Hard-Margin SVM 的主要区别在于

$$\begin{aligned} \nabla_{\xi} L(\omega, b, \alpha, \xi, \mu) &= C - \alpha - \mu = 0 \\ \text{又} \quad & \begin{cases} \alpha_i \geq 0 \\ \mu_i \geq 0 \end{cases} \\ \Rightarrow \quad & 0 \leq \alpha_i \leq C \end{aligned} \quad (20)$$